# Classificação Binária com Computação Quântica: Análise de Separabilidade Linear e Não Linear Utilizando Circuitos Variacionais

Deoclécio Ivo de Melo Netto

***Resumo*—A computação quântica tem emergido como uma alternativa promissora para problemas de aprendizado de máquina, especialmente em cenários que demandam alta capacidade de representação. Este trabalho apresenta a implementação de um classificador quântico baseado em Circuitos Quânticos Variacionais (VQC), aplicado a problemas de classificação binária em dois contextos distintos: dados linearmente separáveis e não linearmente separáveis.**

**O objetivo é investigar a capacidade de modelos quânticos em capturar padrões complexos e comparar seu comportamento em diferentes níveis de dificuldade. Os resultados indicam que o modelo apresenta bom desempenho em ambos os cenários, com destaque para sua flexibilidade na modelagem de fronteiras de decisão não lineares.**

***Index Terms*—Computação Quântica, Quantum Machine Learning, Classificação Binária, Circuitos Variacionais, Separabilidade Linear**

## I. Introdução

O avanço do aprendizado de máquina tem permitido a resolução de problemas complexos em diversas áreas. No entanto, modelos clássicos podem apresentar limitações na representação de padrões altamente não lineares.

Nesse contexto, a computação quântica surge como uma abordagem alternativa, explorando propriedades como superposição e entrelaçamento para processar informação de forma mais expressiva.

Este trabalho investiga o uso de um classificador quântico variacional aplicado a dois tipos de problemas de classificação: linearmente separáveis e não linearmente separáveis. Para a representação dos dados clássicos no circuito quântico, foi utilizada a técnica de *angle encoding*, na qual as características de entrada são mapeadas em rotações parametrizadas de portas quânticas.

## II. Metodologia

### A. Base de Dados

Foram utilizados dois conjuntos de dados sintéticos amplamente empregados em experimentos de classificação:

- **make_blobs**: dataset gerado com distribuição aproximadamente gaussiana, com clusters bem definidos e linearmente separáveis;
- **make_moons**: dataset composto por duas classes em formato de meia-lua, caracterizando um problema não linearmente separável.

O dataset `make_blobs` permite avaliar o comportamento do modelo em cenários simples, nos quais uma fronteira linear é suficiente para separação das classes.

Por outro lado, o `make_moons` apresenta uma estrutura geométrica mais complexa, exigindo maior capacidade de representação para modelar corretamente a fronteira de decisão.

Essa escolha experimental permite comparar diretamente a capacidade do classificador quântico em lidar com diferentes níveis de complexidade, evidenciando sua flexibilidade em problemas não lineares.

### B. Codificação dos Dados (Encoding)

Para a incorporação dos dados clássicos no modelo quântico, foi utilizada a técnica de *angle encoding*, na qual as características de entrada são mapeadas em ângulos de rotação aplicados a portas quânticas.

Antes da codificação, os dados foram reescalados para o intervalo angular $[0, \pi]$, garantindo que cada feature fosse convertida proporcionalmente em radianos. Esse procedimento permite rotações estáveis e adequadas nos qubits durante o processo de *embedding* quântico.

Esse tipo de codificação possibilita representar informações clássicas em estados quânticos de forma eficiente, preservando relações estruturais dos dados e contribuindo para a expressividade do modelo.

### C. Modelo Quântico

O modelo foi implementado utilizando um simulador quântico baseado na biblioteca PennyLane. Foi definido um dispositivo quântico com dois qubits, conforme apresentado a seguir:

```
dev = qml.device("default.qubit", wires=2)
```
(1)

Cada qubit representa uma feature do conjunto de dados, permitindo a codificação direta das variáveis de entrada no circuito quântico.

*1) Dataset Linear (make_blobs):* Para o dataset linearmente separável, foi utilizada uma arquitetura simples, composta por uma única camada variacional.

A codificação dos dados foi realizada por meio de rotações $R_Y$ e $R_X$, enquanto a parte treinável utilizou o template *BasicEntanglerLayers*, responsável por introduzir rotações parametrizadas e entrelaçamento entre os qubits.

0.48

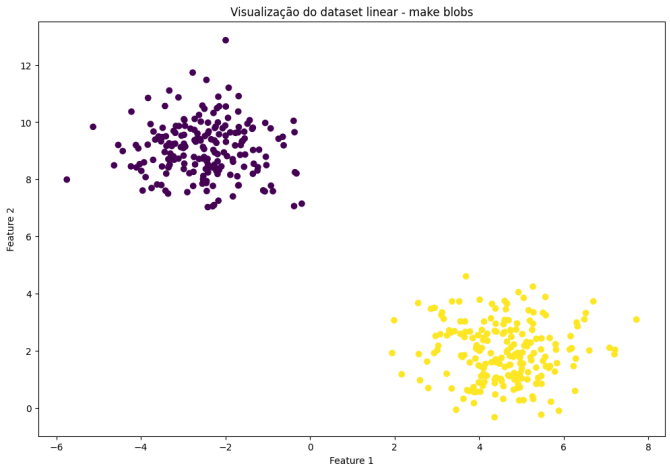


Figura 1: Dataset linear (make_blobs)

0.48

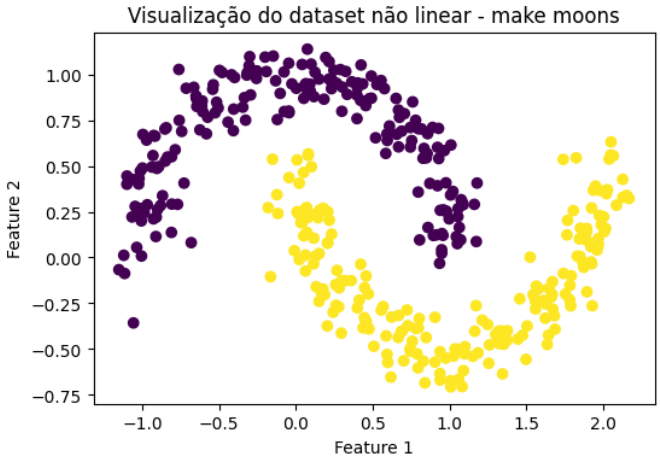


Figura 2: Dataset não linear (make_moons)

Figura 3: Comparação entre datasets linearmente e não linearmente separáveis.

A função de custo adotada foi o erro quadrático médio (MSE), definido como:

$$L = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{2}$$

Essa escolha é adequada para problemas mais simples, nos quais a separação linear pode ser aprendida com baixa complexidade do modelo.

*2) Dataset Não Linear (make_moons):* Para o dataset não linear, foi utilizada uma arquitetura mais profunda, com múltiplas camadas variacionais.

A codificação foi realizada por meio de rotações $R_Y$ em ambos os qubits, seguida pela aplicação do template *StronglyEntanglingLayers*, que introduz maior capacidade de representação ao modelo por meio de múltiplas rotações parametrizadas e operações de entrelaçamento.

Nesse caso, foi utilizada a função de perda de entropia cruzada binária (*Binary Cross-Entropy*), definida como:

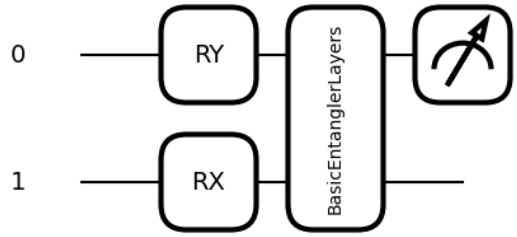


Figura 4: Circuito quântico utilizado para o dataset linear (make_blobs).

$$L = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right] \tag{3}$$

Essa função é mais adequada para problemas de classificação mais complexos, pois penaliza de forma mais eficiente erros de alta confiança.

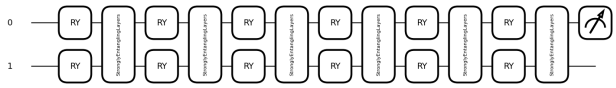

Figura 5: Circuito quântico utilizado para o dataset não linear (make_moons).

*3) Medição:* Em ambos os casos, a saída do modelo é obtida pela medição do valor esperado do operador de Pauli-Z no primeiro qubit:

$$\langle Z \rangle \in [-1, 1] \tag{4}$$

Esse valor é posteriormente transformado para o intervalo $[0, 1]$, permitindo sua interpretação como probabilidade para classificação binária.

### *D. Função de Custo e Treinamento*

O treinamento do modelo foi realizado por meio da minimização de uma função de custo baseada no erro quadrático médio (*Mean Squared Error* - MSE).

Inicialmente, o circuito quântico retorna valores no intervalo $[-1, 1]$, correspondentes ao valor esperado do operador de Pauli-Z. Para compatibilizar essa saída com uma interpretação probabilística, foi aplicada uma transformação linear, convertendo os valores para o intervalo $[0, 1]$:

$$\hat{y} = \frac{f(x) + 1}{2} \tag{5}$$

onde $f(x)$ representa a saída do circuito quântico.

A função de custo é então definida como:

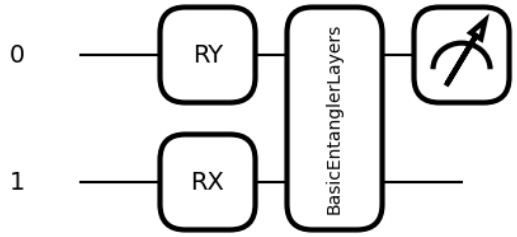


Figura 6: Circuito quântico utilizado para o dataset linear (make_blobs).

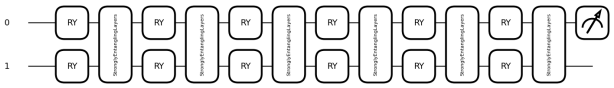

Figura 7: Circuito quântico utilizado para o dataset não linear (make_moons).

$$L = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{6}$$

onde:

- $y_i$ representa o valor real da classe;
- $\hat{y}_i$ representa a predição do modelo;
- $N$ é o número de amostras.

A minimização dessa função permite ajustar os parâmetros do circuito variacional de forma a reduzir o erro entre as predições e os valores reais.

### *E. Otimização dos Parâmetros*

A otimização dos parâmetros do circuito variacional foi realizada utilizando o algoritmo Adam (*Adaptive Moment Estimation*), amplamente empregado em problemas de aprendizado de máquina devido à sua eficiência e estabilidade.

O método Adam combina estimativas de primeira e segunda ordem dos gradientes para ajustar dinamicamente a taxa de aprendizado de cada parâmetro ao longo do treinamento, proporcionando convergência mais rápida em comparação a métodos tradicionais de gradiente descendente.

O processo de treinamento foi conduzido ao longo de múltiplas épocas, nas quais os parâmetros do circuito são atualizados iterativamente com o objetivo de minimizar a função de custo definida anteriormente. Em cada época, os pesos do modelo são ajustados com base no gradiente da função de perda em relação aos parâmetros do circuito.

Durante o treinamento, foi mantido um histórico da função de custo ao longo das épocas, permitindo a análise da convergência do modelo.

A Figura 8 apresenta a evolução da função de custo ao longo das épocas para os dois cenários analisados.

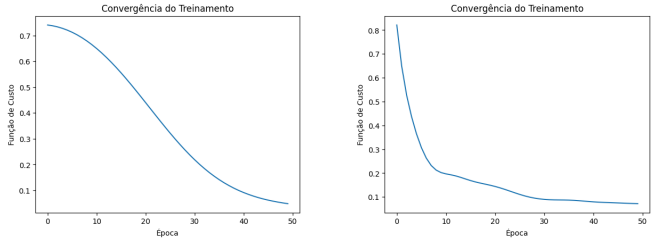


(a) Dataset linear (make_blobs) (b) Dataset não linear (make_moons)

Figura 8: Evolução da função de custo ao longo do treinamento para os dois datasets.

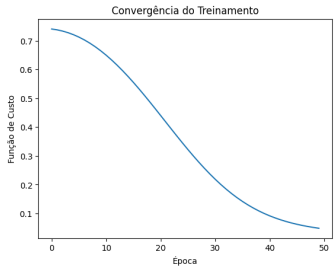


Figura 9: Enter Caption

No dataset linear, observa-se uma convergência rápida da função de perda, refletindo a simplicidade do problema e a capacidade do modelo de encontrar facilmente uma fronteira de decisão adequada.

Por outro lado, no dataset não linear, a convergência ocorre de forma mais gradual, exigindo maior número de iterações devido à complexidade da estrutura dos dados. Ainda assim, o modelo consegue minimizar efetivamente a função de custo, indicando aprendizado adequado mesmo em um cenário mais desafiador.

## III. Resultados

Os resultados obtidos demonstram o desempenho do classificador quântico nos diferentes cenários analisados.

### *A. Dataset Linear*

Como ilustrado na Figura 11, o modelo foi capaz de separar perfeitamente as duas classes, apresentando acurácia de 100% no dataset linear.

Observa-se que a fronteira de decisão é aproximadamente linear, o que está de acordo com a estrutura do conjunto de dados. As regiões de cor indicam a probabilidade prevista pelo modelo, enquanto os pontos representam as amostras reais.

### *B. Dataset Não Linear*

Para o dataset não linear, apresentado na Figura 12, o modelo também foi capaz de atingir acurácia de 100%, demonstrando elevada capacidade de representação.

Diferentemente do caso linear, observa-se que a fronteira de decisão aprendida apresenta comportamento não linear, adaptando-se à geometria complexa dos dados. O modelo

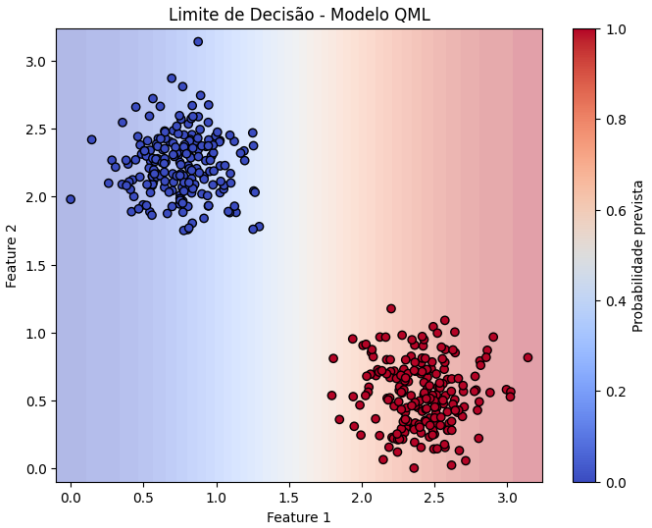


Figura 11: Fronteira de decisão do modelo quântico para o dataset linear.

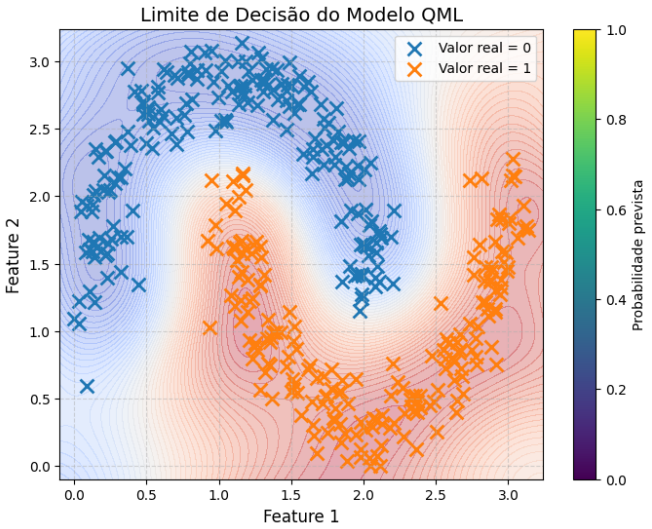


Figura 12: Fronteira de decisão do modelo quântico para o dataset não linear (make_moons).

consegue capturar corretamente a separação entre as classes, mesmo quando estas não são linearmente separáveis no espaço original.

Esse resultado evidencia a importância da utilização de uma arquitetura mais profunda, baseada em *StronglyEntanglingLayers*, que permite ao circuito quântico representar relações mais complexas entre as variáveis de entrada.

Além disso, a utilização da função de perda baseada em entropia cruzada contribui para uma melhor otimização em problemas de classificação mais desafiadores, penalizando de forma mais eficiente previsões incorretas com alta confiança.

### C. Análise Geral

- O modelo apresenta alta acurácia no dataset linear, mesmo com uma arquitetura simples;
- O modelo é capaz de capturar padrões não lineares ao aumentar a profundidade do circuito;
- A escolha da função de perda impacta diretamente o desempenho em problemas mais complexos;
- O uso de circuitos variacionais mais profundos aumenta significativamente a capacidade de representação do modelo.

## IV. Conclusão

Este trabalho investigou o uso de classificadores quânticos variacionais aplicados a problemas de classificação binária com diferentes níveis de complexidade. Foram analisados dois cenários distintos: um dataset linearmente separável (`make_blobs`) e um dataset não linear (`make_moons`).

Os resultados obtidos demonstraram que o modelo quântico foi capaz de alcançar acurácia de 100% em ambos os casos, evidenciando sua capacidade de adaptação a diferentes estruturas de dados. No cenário linear, uma arquitetura simples, baseada em uma única camada variacional com *BasicEntanglerLayers* e otimizada com erro quadrático médio, mostrou-se suficiente para capturar a separação entre as classes.

Por outro lado, no cenário não linear, foi necessária a utilização de uma arquitetura mais profunda, baseada em *StronglyEntanglingLayers*, juntamente com a função de perda de entropia cruzada, permitindo ao modelo capturar relações mais complexas entre as variáveis. Esse resultado reforça a importância da escolha adequada da arquitetura do circuito e da função de custo de acordo com a natureza do problema.

A comparação entre os dois cenários evidencia que o aumento da profundidade do circuito e do nível de entrelaçamento contribui significativamente para a capacidade de representação do modelo quântico, especialmente em problemas não linearmente separáveis.

Apesar dos resultados promissores, é importante destacar que os experimentos foram conduzidos em datasets sintéticos, o que pode facilitar a obtenção de alto desempenho. Assim, trabalhos futuros podem explorar a aplicação desses modelos em bases de dados reais, bem como investigar o impacto de ruído quântico e limitações de hardware em dispositivos quânticos físicos.

Dessa forma, conclui-se que classificadores quânticos variacionais representam uma abordagem viável e promissora para problemas de classificação, especialmente quando combinados com estratégias adequadas de modelagem e otimização.